

Optimisation des Politiques de Reinforcement Learning par Monte Carlo Control

*Analyse statistique de la convergence, comparaison des estimateurs
et réduction de variance*

Auteur Issam Legssair
Filière Statistique et Big Data 2^{ème} année
Année 2025–2026

**Institut National de Statistique
et d'Économie Appliquée INSEA**

Rabat, Maroc

Résumé

Ce rapport présente une étude statistique approfondie de la méthode **Monte Carlo Control** (MCC) pour l'optimisation des politiques dans les **Processus Décisionnels de Markov** (MDP). Le reinforcement learning constitue aujourd'hui l'un des paradigmes les plus puissants de l'intelligence artificielle moderne, au fondement de systèmes tels qu'AlphaGo, AlphaZero, et les modèles de langage entraînés par retour humain (RLHF) comme ChatGPT. Au cœur de ces méthodes se trouvent les **chaînes de Markov** et les **simulations de Monte Carlo**, dont ce travail propose une analyse statistique rigoureuse.

Contrairement à une approche purement informatique centrée sur la performance de l'agent, ce projet adopte un angle résolument statistique. Nous étudions les propriétés théoriques et empiriques des **estimateurs Monte Carlo** de la fonction de valeur d'action $Q^\pi(s, a)$, à savoir le non-biais, la consistance, la vitesse de convergence et la variance. Ces propriétés sont analysées à travers un cadre rigoureux combinant la loi forte des grands nombres, le théorème central limite, les tests statistiques classiques et les outils de diagnostic issus de la littérature MCMC bayésienne.

Le projet est structuré en cinq phases complémentaires. La **Phase 1** pose les fondements théoriques du cadre MDP et des estimateurs Monte Carlo, en s'appuyant sur les grands théorèmes de la probabilité. La **Phase 2** décrit l'implémentation d'un environnement de simulation personnalisé et d'un agent Monte Carlo Control avec exploration ε -greedy. La **Phase 3** constitue le cœur statistique du projet, avec une analyse approfondie de la distribution des retours, du diagnostic de convergence et de la comparaison des estimateurs. La **Phase 4** étend le cadre à l'apprentissage off-policy par l'introduction de l'importance sampling et l'étude du biais-variance tradeoff. Enfin, la **Phase 5** synthétise l'ensemble des résultats sous une forme comparative et unifiée.

Mots-clés : Chaîne de Markov, Processus Décisionnel de Markov, Monte Carlo Control, first-visit, every-visit, loi des grands nombres, théorème central limite, importance sampling, réduction de variance, critère de Gelman-Rubin, reinforcement learning, politique optimale, Q-valeur.

Abstract

This report presents a rigorous statistical study of the **Monte Carlo Control** (MCC) method for policy optimization in **Markov Decision Processes** (MDPs). Reinforcement Learning (RL) stands today as one of the most impactful paradigms in artificial intelligence, underpinning breakthroughs such as AlphaGo, AlphaZero, and large language models trained via Reinforcement Learning from Human Feedback (RLHF). At the mathematical core of these systems lie **Markov chains** and **Monte Carlo simulation**, whose statistical properties are rigorously analyzed in this work.

Rather than focusing solely on agent performance, this project adopts a fundamentally statistical perspective : we study the theoretical and empirical properties of **Monte Carlo estimators** of the action-value function $Q^\pi(s, a)$, including **unbiasedness**, **consistency**, **rate of convergence**, and **variance**.

The project unfolds across five complementary phases. **Phase 1** establishes the theoretical foundations : formalization of the MDP as a controlled Markov chain, the Markov property, Bellman equation, and rigorous proof of the convergence of first-visit and every-visit estimators using the Strong Law of Large Numbers (SLLN) and the Central Limit Theorem (CLT). The convergence rate is shown to be $\mathcal{O}(1/\sqrt{N})$, and 95% confidence intervals are derived analytically. **Phase 2** covers the implementation of a custom 5×5 GridWorld environment and a Monte Carlo Control agent with ε -greedy exploration. Empirical results confirm that the agent successfully learns an optimal policy within a limited number of episodes, and that Q-values converge to their theoretical counterparts as predicted.

Phase 3 constitutes the statistical core of the project. It examines the empirical distribution of Monte Carlo returns G_t , verifies their asymptotic normality through Shapiro-Wilk tests and QQ-plots, compares the variances of both on-policy estimators via Welch's t-test and Levene's test, and diagnoses chain convergence using the **Gelman-Rubin criterion** ($\hat{R} < 1.1$). Autocorrelation Function (ACF) analysis empirically confirms the theoretical result that every-visit introduces within-episode correlations that first-visit avoids by design, explaining the observed bias-variance tradeoff between the two estimators.

Phase 4 extends the analysis to the **off-policy** framework through **importance sampling** (IS). Two estimators are implemented and compared : the ordinary IS estimator, which is unbiased but potentially has infinite variance when importance ratios are large, and the weighted IS estimator, which is slightly biased in finite samples but achieves controlled variance. A bootstrap study (200 replications) quantifies the **bias-variance tradeoff** empirically and demonstrates that the weighted IS estimator minimizes the mean squared error (MSE) across all practical sample sizes.

Phase 5 synthesizes all results through a unified comparative visualization and a summary table of the four estimators studied. All estimators are shown to converge to the same optimal policy $\pi^*(s)$ on the GridWorld environment, while exhibiting the theoretical variance and bias properties established in Phase 1. A real-time animation (GIF) of the learning process is produced, making the convergence of Q-values and the evolution of the policy visually accessible.

The project is structured around five complementary phases. **Phase 1** establishes the theoretical foundations of the MDP framework and Monte Carlo estimators, grounded in the major theorems of probability theory. **Phase 2** describes the implementation of a custom simulation environment and a Monte Carlo Control agent with ε -greedy exploration. **Phase 3** forms the statistical core of the project, with a rigorous analysis of the distribution of returns, convergence diagnostics, and estimator comparison. **Phase 4** extends the framework to off-policy learning through importance sampling and the study of the bias-variance tradeoff. Finally, **Phase 5** synthesizes all results in a unified comparative framework.

Keywords : Markov Chain, Markov Decision Process, Monte Carlo Control, first-visit, every-visit, Law of Large Numbers, Central Limit Theorem, importance sampling, variance reduction, Gelman-Rubin criterion, reinforcement learning, optimal policy, action-value function.

0 Table des matières

1	Introduction	8
1.1	Contexte général et motivation	8
1.2	Positionnement et originalité du projet	8
1.3	Objectifs	9
1.4	Structure du rapport	9
2	Phase 1 Fondements théoriques	10
2.1	Processus Décisionnel de Markov	10
2.2	La propriété de Markov	10
2.3	Retour actualisé et fonction de valeur	11
2.4	Équation de Bellman	11
2.5	Estimateurs Monte Carlo	12
2.6	Convergence Démonstrations	12
2.7	Comparaison first-visit vs every-visit	13
2.8	Démonstration numérique LGN et TCL	13
3	Phase 2 Implémentation et résultats empiriques	15
3.1	Environnement GridWorld 5×5	15
3.2	Algorithme Monte Carlo Control	15
3.2.1	Politique ε -greedy	15
3.2.2	Mise à jour incrémentale	15
3.3	Résultats empiriques	16
3.3.1	Courbes d'apprentissage	16
3.3.2	Politique optimale apprise	17
4	Phase 3 Analyse statistique approfondie de la convergence	19
4.1	Distribution des retours G_t et normalité asymptotique	19
4.2	Comparaison statistique first-visit vs every-visit	22
4.3	Diagnostic de convergence Critère de Gelman-Rubin	22
4.4	Analyse d'autocorrélation des retours G_t	23
5	Phase 4 Réduction de variance par Importance Sampling	25
5.1	Motivation et cadre off-policy	25
5.2	Cadre théorique	25
5.3	Résultats empiriques	26
6	Phase 5 Synthèse comparative	29

6.1	Vue d'ensemble unifiée	29
6.2	Tableau récapitulatif des quatre estimateurs	30
6.3	Hierarchie selon la MSE	30
7	Discussion	31
7.1	Retour sur les objectifs et bilan général	31
7.2	Analyse critique des résultats	31
7.3	Comparaison avec les méthodes alternatives	32
7.4	Limites et perspectives	33
8	Conclusion	34
	Références	35

0 Table des figures

1	Démonstration numérique — LGN et TCL	13
2	Courbes d'apprentissage — First-visit vs Every-visit	16
3	Politique optimale — Estimateur first-visit	17
4	Politique optimale — Estimateur every-visit	17
5	Distribution des retours G_t — Estimateur first-visit	19
6	Distribution des retours G_t — Estimateur every-visit	21
7	Comparaison statistique — First-visit vs Every-visit	22
8	Critère de Gelman-Rubin — $M = 5$ agents indépendants	23
9	Autocorrélation des retours G_t — First-visit vs Every-visit	23
10	Comparaison — On-policy, IS ordinaire et IS pondéré	26
11	Convergence et distribution des ratios IS	27
12	Biais-variance tradeoff — IS ordinaire vs IS pondéré	27
13	Synthèse comparative — Vue d'ensemble du projet	29

1 Introduction

1.1 Contexte général et motivation

Le **Reinforcement Learning** (RL) est un paradigme d'apprentissage automatique dans lequel un agent apprend à prendre des décisions optimales en interagissant de façon itérative avec un environnement stochastique. Contrairement à l'apprentissage supervisé, l'agent ne dispose d'aucun exemple étiqueté : il apprend uniquement par essais et erreurs, guidé par des signaux de récompense qu'il reçoit de l'environnement. Ce paradigme est à la base de systèmes qui ont révolutionné l'intelligence artificielle ces dernières années, notamment AlphaGo (DeepMind, 2016), qui a battu le champion du monde du jeu de Go, et les modèles de langage entraînés par RLHF (Reinforcement Learning from Human Feedback), comme ChatGPT et GPT-4.

Au fondement mathématique du RL se trouvent les **Processus Décisionnels de Markov** (MDP), qui formalisent le problème de la prise de décision séquentielle dans un environnement stochastique. Un MDP est une **chaîne de Markov contrôlée** : l'agent choisit les transitions via sa politique, et l'environnement répond selon des probabilités fixées. L'objectif est de trouver la politique optimale qui maximise la somme actualisée des récompenses futures.

Les méthodes **Monte Carlo** constituent l'une des approches les plus élégantes pour résoudre ce problème : plutôt que de résoudre analytiquement les équations de Bellman (ce qui exige une connaissance complète du modèle et est computationnellement prohibitif pour de grands espaces d'états), elles estiment directement la fonction de valeur en simulant un grand nombre d'épisodes complets et en faisant la moyenne des retours observés. Ce principe est intimement lié aux grands théorèmes de la probabilité : la **loi des grands nombres** garantit la convergence, le **théorème central limite** quantifie la vitesse.

1.2 Positionnement et originalité du projet

Ce projet se distingue des approches classiques par son angle résolument **statistique**. La plupart des projets de RL en informatique se concentrent sur la performance de l'agent (score final, vitesse d'apprentissage). Ici, nous plaçons au centre de l'analyse les **propriétés statistiques des estimateurs** eux-mêmes :

- Sont-ils biaisés ? Convergent-ils vers la vraie valeur ?
- À quelle vitesse convergent-ils ? Peut-on quantifier l'incertitude ?
- Lequel est le plus efficace en termes de biais-variance ?

— Comment diagnostiquer la convergence rigoureusement ?

Ces questions font de ce projet un objet d'étude à l'intersection de la **statistique mathématique**, de la **simulation de Monte Carlo** et du **renforcement learning moderne**.

1.3 Objectifs

- O1. Estimation.** Montrer que l'estimateur Monte Carlo $\hat{Q}_N(s, a)$ est consistant et asymptotiquement non biaisé.
- O2. Convergence.** Caractériser la vitesse de convergence en $\mathcal{O}(1/\sqrt{N})$ et construire des intervalles de confiance empiriques.
- O3. Comparaison.** Comparer statistiquement les estimateurs first-visit, every-visit, IS ordinaire et IS pondéré en termes de biais, variance et MSE.
- O4. Diagnostic.** Appliquer des outils rigoureux de diagnostic de convergence (Gelman-Rubin, ACF, tests de Welch et Shapiro-Wilk).

1.4 Structure du rapport

Ce rapport est organisé en cinq phases progressives, chacune démarrant sur une nouvelle page :

- **Phase 1** Fondements théoriques : MDP, chaînes de Markov, équation de Bellman, estimateurs Monte Carlo et démonstrations de convergence.
- **Phase 2** Implémentation : environnement GridWorld 5×5 , agent Monte Carlo Control avec exploration ε -greedy, visualisation de la politique apprise.
- **Phase 3** Analyse statistique approfondie : distribution des retours G_t , tests de normalité, comparaison de variance, critère de Gelman-Rubin, analyse d'autocorrélation.
- **Phase 4** Réduction de variance : importance sampling off-policy ordinaire et pondéré, biais-variance tradeoff, estimation bootstrap.
- **Phase 5** Synthèse : tableau comparatif des quatre estimateurs, hiérarchie selon la MSE, visualisation unifiée.

2 Phase 1 Fondements théoriques

2.1 Processus Décisionnel de Markov

Définition Processus Décisionnel de Markov (MDP)

Un MDP est un tuple $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ où :

- $\mathcal{S}$: espace d'états fini
- $\mathcal{A}$: espace d'actions fini
- $P(s' | s, a) = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a)$: fonction de transition stochastique
- $R(s, a) = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$: récompense espérée
- $\gamma \in [0, 1)$: facteur d'actualisation

Un MDP est une **chaîne de Markov contrôlée** : la matrice de transition P^π induite par une politique π est exactement la matrice d'une chaîne de Markov classique. L'agent influence les transitions via sa politique, mais les probabilités de l'environnement sont fixées.

2.2 La propriété de Markov

Définition Propriété de Markov

$$\mathbb{P}(S_{t+1} = s' | S_t, A_t, S_{t-1}, A_{t-1}, \dots, S_0) = \mathbb{P}(S_{t+1} = s' | S_t, A_t) \quad (1)$$

Le futur dépend **uniquement** de l'état présent, pas du passé.

Importance pour Monte Carlo. La propriété de Markov garantit que les épisodes simulés sous une politique π sont des trajectoires **indépendantes** conditionnellement à l'état initial. C'est la condition nécessaire et suffisante pour que la loi des grands nombres s'applique et que la moyenne des retours G_t converge vers la vraie valeur $Q^\pi(s, a)$. Sans cette propriété, les observations ne seraient pas indépendantes et l'estimateur Monte Carlo n'aurait aucune garantie de convergence.

2.3 Retour actualisé et fonction de valeur

Définition Retour actualisé G_t

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \quad (2)$$

La condition $\gamma < 1$ garantit la bornitude : $|G_t| \leq R_{\max}/(1-\gamma) < +\infty$. Le facteur γ traduit la préférence temporelle de l'agent : une récompense immédiate vaut plus qu'une récompense future identique.

Définition Fonction de valeur d'action Q^π

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] \quad (3)$$

$Q^\pi(s, a)$ représente l'espérance du retour total actualisé en partant de l'état s , en effectuant l'action a , puis en suivant la politique π . C'est la quantité centrale que Monte Carlo cherche à estimer.

2.4 Équation de Bellman

La fonction Q^π satisfait la récurrence de Bellman :

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \sum_{a'} \pi(a'|s') Q^\pi(s', a') \quad (4)$$

En notation matricielle pour une politique π fixée :

$$\mathbf{Q}^\pi = (\mathbf{I} - \gamma \mathbf{P}^\pi)^{-1} \mathbf{R} \quad (5)$$

La résolution exacte de (5) coûte $\mathcal{O}(|\mathcal{S}|^3)$, prohibitif pour de grands espaces. **Monte Carlo évite ce calcul en estimant Q^π directement par simulation**, sans modèle de l'environnement.

2.5 Estimateurs Monte Carlo

Estimateur First-visit

Soit $\tau_i(s, a)$ le temps de la **première** occurrence de (s, a) dans l'épisode i :

$$\hat{Q}_N^{FV}(s, a) = \frac{1}{N} \sum_{i=1}^N G_{\tau_i(s, a)}^{(i)} \quad (6)$$

On ne retient qu'une seule observation par épisode, garantissant l'indépendance des G_t utilisés.

Estimateur Every-visit

Soit $M = \sum_{i=1}^N n_i(s, a)$ le nombre total de visites de (s, a) :

$$\hat{Q}_M^{EV}(s, a) = \frac{1}{M} \sum_{i=1}^N \sum_{t: (S_t^{(i)}, A_t^{(i)}) = (s, a)} G_t^{(i)} \quad (7)$$

On utilise **toutes** les occurrences de (s, a) , qu'elles soient premières ou non dans l'épisode.

2.6 Convergence Démonstrations

Théorème Convergence de l'estimateur first-visit

Sous la propriété de Markov et si chaque paire (s, a) est visitée infiniment souvent (condition GEI) :

$$\hat{Q}_N^{FV}(s, a) \xrightarrow[N \rightarrow \infty]{\text{p.s.}} Q^\pi(s, a) \quad (8)$$

Preuve. Les $X_i = G_{\tau_i(s, a)}^{(i)}$ sont i.i.d. par la propriété de Markov. Non-biais : $\mathbb{E}[\hat{Q}_N^{FV}] = \mathbb{E}[X_1] = Q^\pi(s, a)$. Convergence p.s. : loi forte des grands nombres, applicable car $\mathbb{E}[|X_1|] \leq R_{\max}/(1 - \gamma) < +\infty$. ■

Proposition Théorème Central Limite

$$\sqrt{N} \left(\hat{Q}_N^{FV}(s, a) - Q^\pi(s, a) \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_{s, a}^2) \quad \text{où } \sigma_{s, a}^2 = \text{Var}(G_t \mid S_t = s, A_t = a) \quad (9)$$

Intervalle de confiance à 95% : $\hat{Q}_N(s, a) \pm 1.96 \cdot \frac{\hat{\sigma}_{s, a}}{\sqrt{N}}$

Remarque Lenteur de convergence

La convergence est en $\mathcal{O}(1/\sqrt{N})$: pour réduire la largeur de l'IC de moitié, il faut multiplier N par 4. Cette lenteur intrinsèque motive les techniques de réduction de variance étudiées en Phase 4.

2.7 Comparaison first-visit vs every-visit

Proposition Biais-variance tradeoff

Puisque $M \geq N$ (every-visit utilise plus d'observations) :

$$\text{Var}(\hat{Q}_N^{FV}) = \frac{\sigma_{s,a}^2}{N} > \text{Var}(\hat{Q}_M^{EV}) \approx \frac{\sigma_{s,a}^2}{M} \quad (10)$$

Every-visit a une variance inférieure, mais les G_t d'un même épisode sont corrélés ($G_t = R_{t+1} + \gamma G_{t+1}$), introduisant un biais en épisodes finis qui disparaît asymptotiquement.

Propriété	First-visit	Every-visit
Biais	Non biaisé	Biaisé (fini), non biaisé asymptotiquement
Variance	σ^2/N	$\approx \sigma^2/M \leq \sigma^2/N$
Indépendance des obs.	Garantie	Non garantie (corrélacion intra-épisode)
Efficacité	Moins efficace	Plus efficace

TABLE 1 – Comparaison des estimateurs first-visit et every-visit.

2.8 Démonstration numérique LGN et TCL




FIGURE 1 – Démonstration numérique — LGN et TCL

Gauche : convergence de la moyenne empirique $\hat{Q}_N$ vers $Q^* = 10$ avec IC à 95% (zone bleue). La largeur de l'IC décroît en $1/\sqrt{N}$ (échelle logarithmique), confirmant la vitesse de convergence théorique prédite par le TCL. On observe que dès $N = 500$ épisodes, l'estimateur est à moins de 0.1 de la vraie valeur.

Droite : distribution empirique des retours G_t avec ajustement normal (courbe rouge). L'adhérence à la gaussienne est très satisfaisante, validant le TCL : les G_t sont asymptotiquement normaux, centrés sur $Q^* = 10$, avec une dispersion de l'ordre de $\hat{\sigma}_{s,a}/\sqrt{N}$.

3 Phase 2 Implémentation et résultats empiriques

3.1 Environnement GridWorld 5×5

Nous implémentons un MDP GridWorld dont les composantes sont :

Composante	Description
$\mathcal{S}$	25 cases (r, c) , $r, c \in \{0, \dots, 4\}$, hors murs $\{(1, 1), (1, 2), (2, 1)\}$
$\mathcal{A}$	$\{0, 1, 2, 3\} = \{\text{haut, bas, gauche, droite}\}$
$P(s' s, a)$	Déterministe. Si la cible est un mur ou un bord, l'agent reste en place.
$R(s, a)$	+10 si $s' = (4, 4)$ (goal), -1 sinon
γ	0.9
État terminal	$(4, 4)$ (coin bas droit)

La récompense de -1 par pas est essentielle : elle incite l'agent à trouver le **chemin le plus court** vers le goal, plutôt que d'errer aléatoirement. Les murs $\{(1, 1), (1, 2), (2, 1)\}$ créent un obstacle qui force l'agent à apprendre un contournement non trivial.

3.2 Algorithme Monte Carlo Control

3.2.1 Politique ε -greedy

$$\pi(a | s) = \begin{cases} 1 - \varepsilon + \varepsilon/|\mathcal{A}| & \text{si } a = \arg \max_{a'} Q(s, a') \\ \varepsilon/|\mathcal{A}| & \text{sinon} \end{cases} \quad \varepsilon_t = \max(0.01, 0.1 \times 0.9995^t) \quad (11)$$

Cette politique assure l'**exploration continue** (condition GEI) : avec probabilité ε , l'agent choisit une action aléatoire, garantissant que toute paire (s, a) est visitée infiniment souvent. Le décroissement de ε traduit la transition progressive de l'exploration vers l'exploitation : l'agent devient plus confiant au fur et à mesure qu'il accumule de l'expérience.

3.2.2 Mise à jour incrémentale

$$Q_n(s, a) = Q_{n-1}(s, a) + \frac{G_t - Q_{n-1}(s, a)}{n} \quad (12)$$

Cette formule évite de stocker tous les retours passés tout en calculant exactement la moyenne empirique. Elle est numériquement stable et s'exécute en mémoire constante $\mathcal{O}(|\mathcal{S}||\mathcal{A}|)$.

3.3 Résultats empiriques

3.3.1 Courbes d'apprentissage




FIGURE 2 — Courbes d'apprentissage — First-visit vs Every-visit

First-visit (bleu) : la récompense démarre très négative lors de la phase d'exploration (ε élevé, 0 à 500 épisodes), puis monte rapidement lors de la phase d'apprentissage (500 à 2500 épisodes), avant de se stabiliser autour d'une valeur positive à la convergence.

Every-visit (vert) : même comportement général mais convergence légèrement plus rapide, conséquence directe de l'utilisation de toutes les visites ($M \geq N$), ce qui réduit la variance et accélère l'apprentissage.

3.3.2 Politique optimale apprise




FIGURE 3 – Politique optimale — Estimateur first-visit

Gauche Heatmap $V(s) = \max_a Q(s,a)$: les cases les plus proches du goal ont les valeurs les plus élevées (vert intense). La décroissance est cohérente avec le facteur $\gamma = 0.9$: une case à k pas du goal vaut environ $\gamma^k \times 10$. Les cases proches des murs ont des valeurs plus basses car l'agent doit les contourner. **Droite Politique optimale** $\pi^*(s)$: les flèches forment un chemin cohérent vers le goal $\star = (4,4)$. L'agent a appris à contourner les murs # par le bas, ce qui est effectivement le chemin optimal. Aucune flèche ne pointe vers un mur ou hors de la grille, validant la cohérence de la politique apprise.




FIGURE 4 – Politique optimale — Estimateur every-visit

Gauche — Heatmap $V(s)$: les valeurs sont légèrement plus concentrées qu'en first-visit (variance réduite), mais la structure spatiale est identique : gradient clair vers le goal, valeurs basses près des murs.

Droite — Politique $\pi^*(s)$: la politique apprise est identique à celle de first-visit, confirmant la convergence des deux estimateurs vers la même solution optimale. Ce résultat est théoriquement attendu : la politique optimale est unique pour un MDP déterministe à récompenses distinctes.

4 Phase 3 Analyse statistique approfondie de la convergence

4.1 Distribution des retours G_t et normalité asymptotique




FIGURE 5 — Distribution des retours G_t — Estimateur first-visit

pour quatre paires (s, a) représentatives. **Colonne gauche Histogramme** : distribution empirique des retours avec ajustement par une loi normale (courbe rouge) et moyenne empirique (ligne verte en tirets). Le test de Shapiro-Wilk ($p > 0.05$ pour les paires bien visitées) confirme la normalité asymptotique prédite par le TCL. **Colonne centrale QQ-plot** : les points s'alignent sur la droite théorique (rouge), confirmant la gaussianité. De légères déviations dans les queues sont attendues : les G_t sont bornés par $R_{\max}/(1 - \gamma)$, contrairement à une vraie gaussienne. **Colonne droite Convergence** : la moyenne cumulative $\hat{Q}_N$ avec IC à 95% (zone bleue). L'IC se resserre en $1/\sqrt{N}$, validant la vitesse théorique.

Phase 3A — Distribution G_t (Every-visit)




FIGURE 6 — Distribution des retours G_t — Estimateur every-visit

Colonne gauche — Histogramme : les distributions sont plus concentrées autour de la moyenne qu'en first-visit (variance inférieure), cohérent avec $\text{Var}^{EV} \leq \text{Var}^{FV}$. Les queues sont légèrement plus lourdes, reflétant la corrélation intra-épisode.

Colonne centrale — QQ-plot : l'alignement est légèrement moins bon qu'en first-visit, conséquence du biais introduit par la dépendance entre observations d'un même épisode.

Colonne droite — Convergence : l'IC se resserre plus vite qu'en first-visit (plus d'observations $M \geq N$), mais la corrélation intra-épisode crée des oscillations plus prononcées en début de courbe.

4.2 Comparaison statistique first-visit vs every-visit




FIGURE 7 — Comparaison statistique — First-visit vs Every-visit

Gauche Moyennes : les estimations $\hat{Q}(s, a)$ des deux méthodes sont très proches pour toutes les paires analysées. Les légères différences sont dues à la variance résiduelle et non à un biais systématique. **Centre Variances** : every-visit présente systématiquement une variance inférieure à first-visit, conformément à la Proposition 2. Le gain est d'autant plus élevé que la paire (s, a) est fréquemment revisitée dans un même épisode. **Droite p-valeurs du test de Welch** : toutes les p-valeurs sont supérieures à 0.05 (seuil horizontal en tirets), ce qui signifie qu'on ne peut pas rejeter H_0 (égalité des moyennes). Conclusion : les deux estimateurs convergent vers la même valeur $Q^\pi(s, a)$, mais every-visit le fait avec une variance moindre.

4.3 Diagnostic de convergence Critère de Gelman-Rubin

Le critère de Gelman-Rubin $\hat{R}$ compare la variance *intra*-chaîne W et la variance *inter*-chaînes B sur $M = 5$ agents indépendants :

$$W = \frac{1}{M} \sum_{m=1}^M s_m^2, \quad B = \frac{N}{M-1} \sum_{m=1}^M (\bar{\theta}_m - \bar{\theta})^2, \quad \hat{V} = \frac{N-1}{N} W + \frac{M+1}{MN} B, \quad \hat{R} = \sqrt{\frac{\hat{V}}{W}} \quad (13)$$




FIGURE 8 – Critère de Gelman-Rubin — $M = 5$ agents indépendants

Gauche Évolution de $\hat{R}$: le critère démarre à des valeurs élevées ($\hat{R} \gg 1$) indiquant une grande dispersion entre les chaînes, puis décroît régulièrement pour passer sous le seuil $\hat{R} < 1.1$ (ligne rouge en tirets) autour de $N \approx 500-1000$ épisodes. Ce résultat signifie que tous les agents indépendants ont convergé vers la même estimation de $Q^\pi(s, a)$. **Droite Trajectoires des 5 agents** : initialement dispersées, les courbes de $\hat{Q}_N$ se resserrent progressivement autour d'une valeur commune, visualisant graphiquement la convergence que $\hat{R}$ quantifie. Ce comportement est exactement celui attendu par la loi forte des grands nombres.

4.4 Analyse d'autocorrélation des retours G_t




FIGURE 9 – Autocorrélation des retours G_t — First-visit vs Every-visit

First-visit (gauche) : l'ACF chute immédiatement vers zéro dès le lag 1 et reste dans l'IC à 95% (lignes rouges). Les G_t first-visit sont pratiquement indépendants : chaque observation vient d'un épisode distinct, sans lien avec les précédentes.

Every-visit (droite) : l'autocorrélation aux premiers lags est significativement plus élevée (sort de l'IC), conséquence de la corrélation intra-épisode. Comme $G_t = R_{t+1} + \gamma G_{t+1}$, deux retours du même épisode partagent des récompenses futures communes, créant une dépendance structurelle qui explique le biais d'every-visit en épisodes finis.

5 Phase 4 Réduction de variance par Importance Sampling

5.1 Motivation et cadre off-policy

La convergence Monte Carlo on-policy en $\mathcal{O}(1/\sqrt{N})$ présente deux limitations importantes. Premièrement, la lenteur intrinsèque : pour réduire l'IC de moitié, il faut quadrupler N . Deuxièmement, le problème de couverture : pour estimer $Q^\pi(s, a)$, l'agent doit visiter (s, a) sous π , ce qui est rare pour les paires éloignées du chemin habituel. L'**importance sampling** résout ces deux problèmes : on génère les épisodes sous une politique de comportement b , plus exploratoire, et on corrige le biais par un poids statistique.

5.2 Cadre théorique

Soit π la politique *cible* ($\varepsilon_\pi = 0.01$, quasi-greedy) et b la politique de *comportement* ($\varepsilon_b = 0.3$, très exploratoire). Le ratio d'importance sampling mesure le rapport des probabilités :

$$\rho_{t:T} = \prod_{k=t}^{T-1} \frac{\pi(A_k | S_k)}{b(A_k | S_k)} \quad (14)$$

Ce ratio vaut 1 si $\pi = b$ (cas on-policy), et s'éloigne de 1 d'autant plus que les politiques diffèrent. Il corrige le fait que certaines trajectoires sont sur-représentées sous b par rapport à ce qu'elles seraient sous π .

Estimateur IS ordinaire (non biaisé)

$$\hat{Q}_N^{IS}(s, a) = \frac{1}{N} \sum_{i=1}^N \rho_{t:T}^{(i)} G_t^{(i)} \quad (15)$$

Propriété : $\mathbb{E}[\hat{Q}_N^{IS}] = Q^\pi(s, a)$ (non biaisé). **Limite** : si ρ prend des valeurs très grandes, la variance peut être infinie, rendant l'estimateur inutilisable en pratique.

Estimateur IS pondéré (variance contrôlée)

$$\hat{Q}_N^{WIS}(s, a) = \frac{\sum_{i=1}^N \rho^{(i)} G_t^{(i)}}{\sum_{i=1}^N \rho^{(i)}} \quad (16)$$

Propriété : biaisé en N fini (dénominateur stochastique), mais la variance est contrôlée et le biais décroît en $\mathcal{O}(1/N)$. Converge p.s. vers $Q^\pi(s, a)$ par la loi des grands nombres.

5.3 Résultats empiriques




FIGURE 10 – Comparaison — On-policy, IS ordinaire et IS pondéré

Gauche Estimations $\hat{Q}(s, a)$: les trois estimateurs convergent vers des valeurs très proches pour toutes les paires analysées. Les légères différences sont dues à la variance résiduelle et aux différences de dénominateurs entre IS ordinaire et pondéré. La cohérence entre estimateurs valide la correction IS : même en utilisant une politique de comportement b très différente de π , on retrouve les mêmes Q -valeurs qu'en on-policy. **Droite Variances** : IS ordinaire peut présenter une variance élevée (ratios ρ potentiellement grands), tandis qu'IS pondéré maintient une variance comparable à celle de l'estimateur on-policy.




FIGURE 11 – Convergence et distribution des ratios IS

convergent vers la même valeur limite, mais avec des comportements très différents. On-policy first-visit (bleu) converge régulièrement. IS ordinaire (rouge) présente des oscillations importantes dues aux ratios ρ élevés : certains épisodes sont extrêmement fortement pondérés, créant des sauts dans la moyenne. IS pondéré (vert) converge de façon plus stable car les poids se compensent au dénominateur. **Droite Distribution des ratios ρ** : les ratios sont concentrés près de 1 (les deux politiques sont proches localement), mais une queue de distribution existe vers des valeurs élevées. Ces ratios élevés correspondent à des trajectoires que π emprunterait avec probabilité bien supérieure à b , et sont la source principale d'instabilité de l'IS ordinaire.




FIGURE 12 – Biais-variance tradeoff — IS ordinaire vs IS pondéré

Gauche Biais : IS ordinaire reste non biaisé pour tout N (biais nul théorique), tandis qu'IS pondéré présente un biais non nul pour les petits N qui décroît en $\mathcal{O}(1/N)$ à mesure que N augmente. **Centre Variance** : IS ordinaire a une variance très élevée pour les petits N (conséquence des grands ratios ρ), contre une variance bien contrôlée pour IS pondéré. **Droite $\text{MSE} = \text{Biais}^2 + \text{Variance}$** : IS pondéré minimise systématiquement la MSE pour tout N pratique, malgré son biais. Cela démontre que le gain en variance compense largement le coût du biais : IS pondéré est l'estimateur à privilégier en pratique.

Bilan Phase 4

IS pondéré domine IS ordinaire selon le critère MSE pour tout N pratique. Son biais, bien que non nul, décroît en $\mathcal{O}(1/N)$ tandis que la réduction de variance est immédiate dès les premiers épisodes. C'est l'estimateur recommandé pour les applications off-policy en reinforcement learning.

6 Phase 5 Synthèse comparative

6.1 Vue d'ensemble unifiée




FIGURE 13 – Synthèse comparative — Vue d'ensemble du projet

Haut gauche — Courbes de convergence : les trois méthodes atteignent le même niveau de récompense finale. Every-visit converge légèrement plus vite ; IS off-policy part d’une politique différente mais converge vers la même valeur, validant la correction par poids ρ .

Haut droite — Politique optimale : $\pi^*(s)$ apprise par first-visit après 5000 épisodes. Les flèches tracent le chemin optimal vers le goal en contournant les obstacles.

Bas gauche — Tableau récapitulatif : variances empiriques des quatre estimateurs sur les paires analysées, confirmant la hiérarchie théorique : IS pondéré $\prec$ every-visit $\prec$ first-visit en variance.

Bas droite — Distribution des G_t : FV et EV sur la même paire (s, a) . La distribution EV est plus concentrée (variance inférieure), illustrant visuellement le gain d’efficacité d’every-visit.

6.2 Tableau récapitulatif des quatre estimateurs

Estimateur	Biais	Variance	Type	Convergence	MSE
First-visit MC	Non biaisé	σ^2/N	On-policy	p.s. (LGN)	Référence
Every-visit MC	Faible	$< \sigma^2/N$	On-policy	p.s. asympt.	Meilleure que FV
IS ordinaire	Non biaisé	Peut être très grande	Off-policy	p.s.	Déconseillée
IS pondéré	Faible	Contrôlée	Off-policy	p.s. asympt.	Meilleure en pratique

TABLE 2 – Récapitulatif des propriétés statistiques des quatre estimateurs.

6.3 Hiérarchie selon la MSE

En combinant les résultats des Phases 3 et 4, on établit la hiérarchie suivante pour un N pratique (typiquement quelques milliers d’épisodes) :

- IS pondéré** : meilleure MSE. Variance contrôlée, biais décroissant en $1/N$. Recommandé quand la couverture on-policy est insuffisante.
- Every-visit MC** : variance inférieure à first-visit, biais asymptotiquement nul. Recommandé quand on dispose de beaucoup d’épisodes et que la corrélation intra-épisode est faible.
- First-visit MC** : non biaisé, référence théorique. Recommandé quand l’absence de biais est prioritaire ou pour la validation.
- IS ordinaire** : non biaisé mais variance potentiellement infinie. Déconseillé en pratique sauf quand les ratios ρ sont bien contrôlés.

7 Discussion

7.1 Retour sur les objectifs et bilan général

Ce projet avait pour ambition de placer la méthode Monte Carlo Control sous un angle résolument statistique, en allant au-delà de la simple observation que l’agent apprend. Les quatre objectifs fixés en introduction ont été atteints.

Objectif 1 Estimation. L’estimateur first-visit $\hat{Q}_N^{FV}(s, a)$ a été rigoureusement démontré non biaisé et consistant. La preuve repose sur la propriété de Markov (indépendance des épisodes) et la loi forte des grands nombres. La validation numérique sur un MDP de référence ($Q^* = 10$, $\gamma = 0.9$) confirme la convergence avec une précision de l’ordre de 10^{-3} après 5000 épisodes.

Objectif 2 Convergence. Le théorème central limite a permis de quantifier la vitesse : la convergence est en $\mathcal{O}(1/\sqrt{N})$, et des intervalles de confiance à 95% ont été construits et validés empiriquement. Le critère de Gelman-Rubin ($\hat{R} < 1.1$ atteint vers $N \approx 500\text{--}1000$ épisodes) fournit un diagnostic objectif de convergence, directement importé de la littérature MCMC et adapté ici au cadre RL.

Objectif 3 Comparaison. Les tests statistiques (Welch, Levene, Shapiro-Wilk) et l’analyse ACF ont permis de caractériser précisément les différences entre estimateurs. Le résultat principal est que **les quatre estimateurs convergent vers la même politique optimale**, mais avec des propriétés statistiques très différentes. La hiérarchie selon la MSE place IS pondéré en tête pour un N pratique, suivi d’every-visit, first-visit et IS ordinaire.

Objectif 4 Diagnostic. L’utilisation du critère de Gelman-Rubin et de l’ACF a apporté une valeur ajoutée significative par rapport à une analyse naïve. En particulier, l’ACF a révélé que l’hypothèse d’indépendance des G_t , fondamentale pour la LGN, est satisfaite par first-visit mais seulement approximativement par every-visit : la corrélation intra-épisode crée une dépendance structurelle que les tests classiques peuvent manquer.

7.2 Analyse critique des résultats

Sur la convergence de $\hat{R}$. Le critère de Gelman-Rubin a été utilisé ici de façon analogue à son usage en MCMC bayésien : plusieurs chaînes indépendantes (agents) sont lancées, et $\hat{R}$ mesure si elles ont convergé vers la même distribution. Cependant, il convient de noter une différence importante : en MCMC, les chaînes explorent une

distribution stationnaire fixe. Ici, les chaînes convergent vers une valeur fixe $Q^\pi(s, a)$. L'adaptation est valide mais l'interprétation doit tenir compte de ce contexte. Le seuil $\hat{R} < 1.1$ est conservateur : en pratique, $\hat{R} < 1.05$ serait préférable pour une convergence plus robuste.

Sur la variance d'IS ordinaire. Les résultats empiriques montrent qu'IS ordinaire peut présenter une variance considérable, en particulier pour les paires (s, a) où les politiques π et b diffèrent fortement. Théoriquement, la variance d'IS ordinaire est infinie si les ratios ρ ne sont pas bornés : $\text{Var}(\rho G_t) = \infty$ dès que $\text{Var}(\rho) = \infty$. Dans notre implémentation, les politiques ε -greedy garantissent $\rho_{t:T} \leq (1/\varepsilon_b)^T$, ce qui borne la variance pour des épisodes de longueur finie, mais la borne peut être très grande.

Sur la normalité des G_t . Les tests de Shapiro-Wilk confirment la normalité asymptotique, mais révèlent des déviations pour les petits échantillons ($n < 50$). Cela est théoriquement attendu : le TCL s'applique en limite, et la convergence vers la normale est d'autant plus lente que la distribution des G_t est asymétrique. Sur GridWorld, les G_t peuvent prendre des valeurs très négatives (longues trajectoires sans trouver le goal) ou modérément positives, créant une asymétrie à gauche qui ralentit la convergence vers la normale.

Sur le choix de γ . Le facteur $\gamma = 0.9$ est un compromis : une valeur plus proche de 1 donnerait plus de poids aux récompenses futures (agent moins myope) mais augmenterait la variance des G_t (la borne $R_{\max}/(1 - \gamma)$ augmente). Une valeur plus faible réduirait la variance mais biaiserait l'agent à ignorer les récompenses lointaines. Le choix $\gamma = 0.9$ est standard dans la littérature pour des problèmes de taille similaire.

7.3 Comparaison avec les méthodes alternatives

Les méthodes Monte Carlo, étudiées ici, se distinguent des autres grandes familles de méthodes RL :

- **Programmation dynamique (DP)** : résout exactement les équations de Bellman mais nécessite une connaissance complète du modèle $P(s'|s, a)$. Coût : $\mathcal{O}(|\mathcal{S}|^2|\mathcal{A}|)$ par itération. Monte Carlo ne nécessite aucun modèle mais converge plus lentement.
- **Temporal Difference (TD)** : même avantage sans modèle, mais mise à jour à chaque pas et non en fin d'épisode. TD a une variance inférieure à MC (moins de bruit par mise à jour) mais un biais plus élevé (bootstrap). Q-learning (TD off-policy) converge plus vite que MC off-policy avec IS mais nécessite plus d'hypothèses.

-
- **Actor-Critic** : combine MC (estimation de la valeur) et gradient de politique (mise à jour). C'est l'architecture utilisée dans RLHF (ChatGPT). Les méthodes MC étudiées ici sont le fondement théorique de ces approches modernes.

En termes de **biais-variance**, on peut établir : DP (biais nul, variance nulle mais modèle requis) $\succ$ TD (biais faible, variance faible) $\succ$ MC (biais nul, variance élevée). Monte Carlo a l'avantage d'être facilement parallélisable (les épisodes sont indépendants) et de ne faire aucune hypothèse sur la structure du MDP.

7.4 Limites et perspectives

Limites de l'environnement. GridWorld est un environnement déterministe de petite taille ($|\mathcal{S}| = 22$, $|\mathcal{A}| = 4$). Les estimateurs peuvent y couvrir l'espace d'états complet en peu d'épisodes, ce qui n'est pas représentatif des applications réelles (Atari : $|\mathcal{S}| > 10^6$, chess : $> 10^{40}$). Dans ces contextes, la convergence est beaucoup plus lente et les approches par approximation de fonction (deep RL) sont nécessaires.

Perspectives immédiates.

- **Validation sur Blackjack** : l'environnement Blackjack-v1 de Gymnasium dispose d'une solution analytique exacte, permettant de valider rigoureusement les estimateurs en comparant $\hat{Q}_N(s, a)$ à la vraie valeur $Q^*(s, a)$.
- **Quasi-Monte Carlo** : remplacer les nombres pseudo-aléatoires par des séquences à faible discrédance (Halton, Sobol) pourrait améliorer la vitesse de convergence en $\mathcal{O}((\log N)^d/N)$.
- **Variables de contrôle** : une autre technique de réduction de variance consistant à soustraire une fonction corrélée à G_t dont on connaît l'espérance.

Perspectives à long terme.

- Extension aux méthodes actor-critic (A2C, PPO) qui utilisent MC pour estimer l'avantage $A(s, a) = Q(s, a) - V(s)$.
- Application RLHF : utiliser MC Control pour optimiser une politique de modèle de langage sur la base de retours humains.
- Analyse bayésienne : utiliser MCMC (Metropolis-Hastings, HMC) pour estimer la distribution postérieure sur les Q-valeurs plutôt qu'un estimateur ponctuel.

8 Conclusion

Ce projet a présenté une étude statistique rigoureuse et complète de la méthode Monte Carlo Control pour l’optimisation des politiques dans les processus décisionnels de Markov. En adoptant une perspective centrée sur les propriétés des **estimateurs statistiques** plutôt que sur la seule performance de l’agent, nous avons pu établir un cadre d’analyse original qui connecte la théorie statistique classique au reinforcement learning moderne.

Les contributions principales de ce travail sont au nombre de quatre. Sur le plan **théorique**, nous avons formalisé le MDP comme chaîne de Markov contrôlée, démontré rigoureusement la convergence des estimateurs first-visit et every-visit par la loi forte des grands nombres, quantifié la vitesse de convergence par le théorème central limite, et établi le biais-variance tradeoff entre les quatre estimateurs étudiés. Sur le plan **empirique**, l’implémentation sur GridWorld a validé toutes les prédictions théoriques : normalité asymptotique des G_t , convergence en $\mathcal{O}(1/\sqrt{N})$, supériorité de l’IS pondéré en MSE, et convergence de Gelman-Rubin vers $\hat{R} < 1.1$.

Sur le plan **méthodologique**, l’utilisation du critère de Gelman-Rubin et de l’analyse ACF, habituellement réservés au cadre MCMC bayésien, représente une contribution originale au diagnostic de convergence en RL. Ces outils permettent de répondre à la question : «combien d’épisodes sont nécessaires pour que l’estimation soit fiable ? », ce qui est crucial pour les applications pratiques. Enfin, sur le plan **pédagogique**, le code Python unique et reproductible, combiné à une animation en temps réel, rend le processus d’apprentissage visible et intuitivement compréhensible.

Les résultats de ce projet ouvrent des perspectives importantes. L’IS pondéré, démontré optimal en MSE, est directement applicable à des problèmes de grande échelle où l’exploration on-policy est coûteuse. La connexion entre Monte Carlo RL et les méthodes MCMC bayésiennes suggère des ponts féconds entre ces deux domaines, notamment pour la quantification d’incertitude dans les modèles d’apprentissage profond. Plus fondamentalement, ce projet illustre que le reinforcement learning, souvent présenté comme un domaine informatique, est profondément enraciné dans la statistique mathématique : la loi des grands nombres, le théorème central limite et la théorie de l’estimation sont ses fondations incontournables.

8 Références

- [1] Sutton, R.S. & Barto, A.G. (2018). *Reinforcement Learning : An Introduction* (2nd ed.). MIT Press. <http://incompleteideas.net/book/the-book.html>
- [2] Puterman, M.L. (1994). *Markov Decision Processes : Discrete Stochastic Dynamic Programming*. John Wiley & Sons.
- [3] Silver, D. (2015). *Lectures on Reinforcement Learning*, Lecture 4 : Model-Free Prediction. University College London. <https://www.davidsilver.uk/teaching/>
- [4] Norris, J.R. (1997). *Markov Chains*. Cambridge University Press.
- [5] Rubinstein, R.Y. & Kroese, D.P. (2016). *Simulation and the Monte Carlo Method* (3rd ed.). Wiley.
- [6] Gelman, A. & Rubin, D.B. (1992). Inference from iterative simulation using multiple sequences. *Statistical Science*, 7(4), 457–472.
- [7] Precup, D., Sutton, R.S. & Singh, S. (2000). Eligibility traces for off-policy policy evaluation. *Proceedings of ICML 2000*, 759–766.
- [8] Robert, C.P. & Casella, G. (2004). *Monte Carlo Statistical Methods* (2nd ed.). Springer.